SB-Scraper

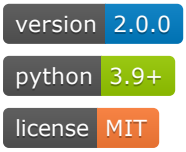

SeleniumBase tabanlı, gelişmiş anti-detection özelliklerine sahip web scraping API'si. Modern web sitelerini taramak, ekran görüntüsü almak, HTML kaynak kodlarını toplamak ve arama motoru sonuçlarını analiz etmek için tasarlanmıştır.

📋 İçindekiler

✨ Özellikler

🔓 Anti-Detection Özellikleri

- **WebDriver Gizleme:** `navigator.webdriver` özelliğini manipüle ederek bot tespitini önler
- **Canvas Fingerprinting Koruması:** Dinamik ve tutarlı canvas gürültüsü ekler
- **WebGL Fingerprinting Koruması:** Vendor ve renderer bilgilerini standartlaştırır
- **Audio Fingerprinting Koruması:** AudioContext ve analizör fonksiyonlarını manipüle eder
- **Font Fingerprinting Koruması:** Font detection API'yi filtreler
- **Screen/Display Manipülasyonu:** Ekran çözünürlük değerlerini hafifçe değiştirir
- **User Agent Rotasyonu:** Windows, macOS ve Linux için farklı User Agent'lar
- **Chrome Object Emülasyonu:** Gerçek Chrome tarayıcı gibi görünür

🌓 Captcha Çözme

- **Google Consent:** Google çerez onay formlarını otomatik kabul eder
- **Cloudflare:** Cloudflare captcha checkbox'larını tıklar
- **ReCaptcha:** Google ReCaptcha checkbox'larını çözer
- **Turnstile:** Cloudflare Turnstile captcha'larını çözer
- **HCaptcha:** HCaptcha checkbox'larını çözer

🎯 Scraping Özellikleri

- **Ham URL Taraması:** Verilen URL'i doğrudan tarar

- **Ana Domain Taraması:** URL'in ana domainini (homepage) de tarar
- **Mobil Görünüm:** Mobil cihaz ekran görüntüleri (375x812)
- **HTML Kaynak Kodu:** Sayfa kaynak kodlarını Base64 formatında alır
- **Google Arama:** Siteyi Google'da aratıp sonuç ekran görüntüsünü alır
- **DuckDuckGo Arama:** Siteyi DuckDuckGo'da aratıp sonuç ekran görüntüsünü alır

🚫 Black-List Koruması

- 500+ önceden tanımlanmış domain filtresi
- URL ve domain bazlı kontrol
- Otomatik filtreleme ve loglama

🧹 Popup Temizleme (Sentinel JS)

- Akıllı popup tespiti ve temizleme
- Z-index bazlı overlay kontrolü
- Yasaklı kelime filtrelemesi
- Geometrik av (yan bantlar, tam ekran overlay'ler)
- MutationObserver ile sürekli DOM izleme

📊 Loglama

- Renkli konsol logları
- Dosya tabanlı loglama (info.log, error.log)
- Otomatik log rotasyonu (10 MB)
- Log saklama süresi (7-30 gün)

🏗️ Teknik Mimari

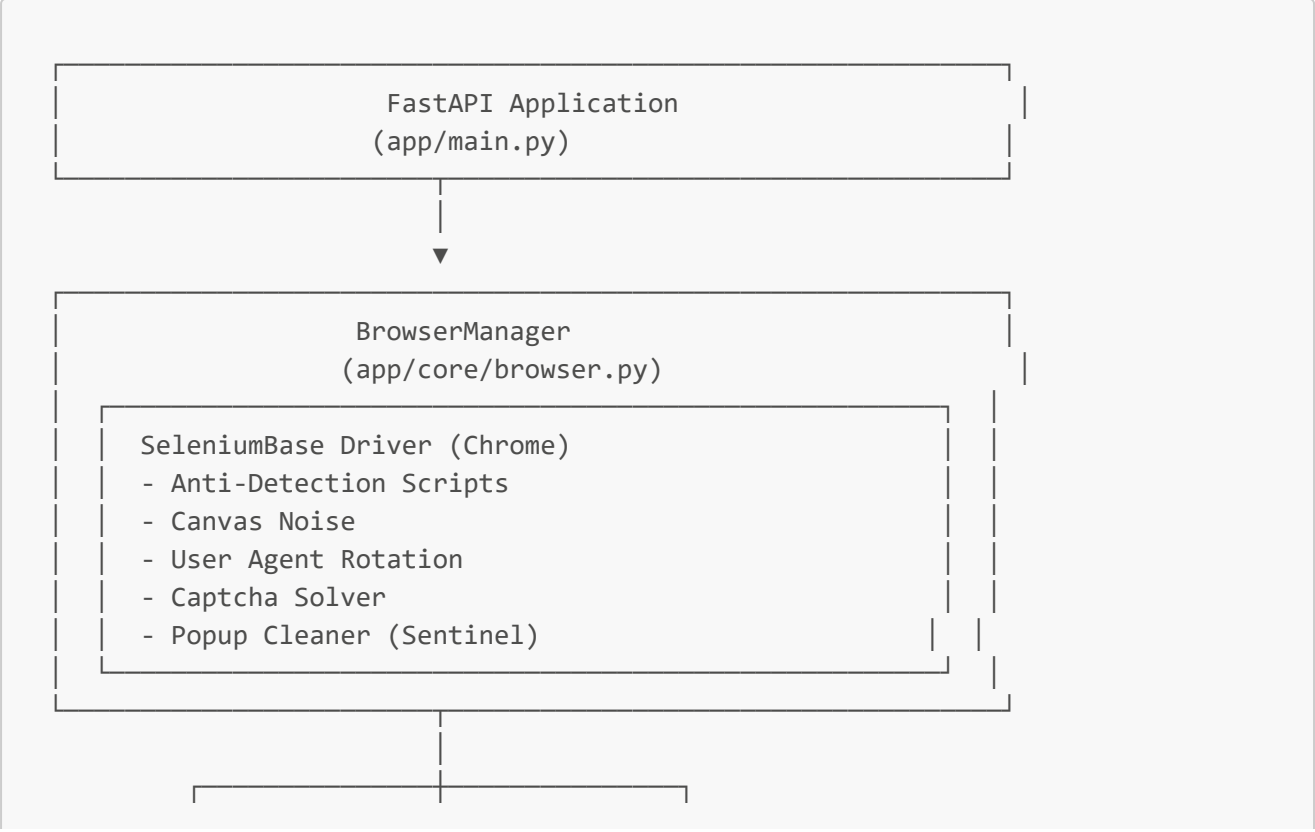

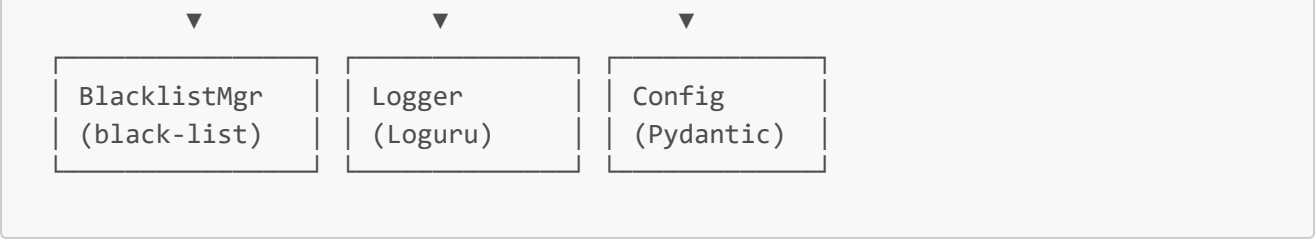

Kurulum

Gereksinimler

- Python 3.9+
- Docker (Docker ile çalıştırmak için)
- Google Chrome

Manuel Kurulum

```
# Depoyu klonlayın
git clone https://github.com/example/sb-scrapper.git
cd sb-scrapper

# Sanal ortam oluşturun
python -m venv venv
source venv/bin/activate  # Windows: venv\Scripts\activate

# Bağımlılıkları yükleyin
pip install -r requirements.txt

# .env dosyasını oluşturun
cp .env.example .env

# .env dosyasını düzenleyin
nano .env
```

Docker ile Çalıştırma

Hızlı Başlatma

```
# Konteyneri başlat
docker-compose up -d

# Logları izle
docker-compose logs -f

# Konteyneri durdur
docker-compose down
```

Ortam Değişkenleri

```
# docker-compose.yml veya .env dosyasında
HEADLESS=true          # Headless mod (true/false)
WAIT_TIME=8            # Sayfa yükleme bekleme süresi (saniye)
LOG_LEVEL=INFO         # Log seviyesi (DEBUG, INFO, WARNING, ERROR)
BLACKLIST_FILE=black-list.lst  # Black-list dosya yolu
PORT=8000              # API portu
```

🚀 Kullanım

Python ile Kullanım

```
import requests
import base64

API_URL = "http://localhost:8000/analyze"

payload = {
    "url": "https://example.com",
    "wait_time": 10,
    "process_raw_url": True,
    "process_main_domain": True,
    "get_html": True,
    "get_mobile_ss": True,
    "get_google_search": True,
    "get_google_html": True,
    "get_ddg_search": True,
    "get_ddg_html": True,
    "force_refresh": False
}

response = requests.post(API_URL, json=payload, timeout=180)
result = response.json()

# Ekran görüntüsünü kaydet
if result.get('raw_desktop_ss'):
    img_data = base64.b64decode(result['raw_desktop_ss'].split(',')[1])
    with open("screenshot.png", "wb") as f:
        f.write(img_data)

print(f"Durum: {result['status']}")
print(f"Süre: {result['duration']:.2f} saniye")
print(f"Loglar: {result['logs']}")
```

cURL ile Kullanım

```
curl -X POST "http://localhost:8000/analyze" \
  -H "Content-Type: application/json" \
  -d '{
    "url": "https://example.com",
    "wait_time": 10,
    "process_raw_url": true,
    "process_main_domain": true,
    "get_html": true,
    "get_mobile_ss": true,
    "get_google_search": true,
    "get_ddg_search": true
  }'
```

📖 API Dokümantasyonu

Endpoint'ler

1. GET `/` - API Durum Kontrolü

API'nin çalışıp çalışmadığını kontrol eder.

Response:

```
{
  "status": "ok",
  "message": "SB-Scraper API is running"
}
```

2. GET `/health` - Sağlık Kontrolü

API'nin ve tarayıcının sağlık durumunu kontrol eder.

Response:

```
{
  "status": "healthy"
}
```

3. POST `/analyze` - URL Analizi Yap

Belirtilen URL'i tarar ve çeşitli çıktılar üretir.

Request Body:

```
{
  "url": "https://example.com",
  "wait_time": 8,
  "process_raw_url": true,
  "process_main_domain": true,
  "get_html": true,
  "get_mobile_ss": true,
  "get_google_search": true,
  "get_google_html": true,
  "get_ddg_search": true,
  "get_ddg_html": true,
  "force_refresh": false
}
```

Parametreler:

Parametre	Tip	Zorunlu	Varsayılan	Açıklama
`url`	string	Evet	-	Taranacak web sitesi adresi
`wait_time`	integer	Hayır	8	Sayfa yüklendikten sonra beklenecek saniye (1-60)
`process_raw_url`	boolean	Hayır	true	Verilen URL'i doğrudan tarar
`process_main_domain`	boolean	Hayır	true	URL'in ana domainini (homepage) de tarar
`get_html`	boolean	Hayır	true	HTML kaynak kodunu alır
`get_mobile_ss`	boolean	Hayır	true	Mobil ekran görüntüsü alır
`get_google_search`	boolean	Hayır	true	Google arama sonucu alır
`get_google_html`	boolean	Hayır	true	Google arama sonucu HTML'ini alır
`get_ddg_search`	boolean	Hayır	true	DuckDuckGo arama sonucu alır
`get_ddg_html`	boolean	Hayır	true	DuckDuckGo arama sonucu HTML'ini alır
`force_refresh`	boolean	Hayır	false	Tarayıcıyı zorla yeniden başlatır

Response:

```
{
  "status": "success",
  "raw_desktop_ss": "...",
  "raw_mobile_ss": "...",
  "raw_html": "PGh0bWw+PGhlYWQ+Li4uPC9oZWFkPjwvaHRtbD4=",
  "main_desktop_ss": "...",
  "google_ss": "...",
```

```
  "google_html": "PGh0bWw+PGhlYWQ+Li4uPC9oZWFkPjwvaHRtbD4=",
  "ddg_ss": "...",
  "ddg_html": "PGh0bWw+PGhlYWQ+Li4uPC9oZWFkPjwvaHRtbD4=",
  "logs": [
    "Adım 1: Ham URL -> https://example.com",
    "☑ Google Çerezi Tıklandı",
    "☑ Bitti"
  ],
  "duration": 12.45,
  "blacklisted_domain": null
}
```


Durum Kodları:

- `200` - Başarılı
- `429` - Tarayıcı meşgul (BUSY)
- `500` - İç sunucu hatası

Durum Değerleri:

- `success` - İşlem başarıyla tamamlandı
- `error` - İşlem sırasında hata oluştu
- `blacklisted` - Domain black-list'te bulundu

Swagger UI

API dokümantasyonu için Swagger UI kullanılabilir:

```
http://localhost:8000/docs
```

Alternatif olarak ReDoc:

```
http://localhost:8000/redoc
```

⚙ Konfigürasyon

.env Dosyası

```
# Tarayıcı Ayarları
HEADLESS=true          # Headless mod (true/false)
WAIT_TIME=8            # Sayfa yükleme bekleme süresi (saniye)
USER_AGENT_PLATFORM=windows  # User Agent platform (windows/macos/linux)

# API Ayarları
HOST=0.0.0.0           # API host adresi
```

```
PORT=8000              # API portu

# Loglama Ayarları
LOG_LEVEL=INFO         # Log seviyesi (DEBUG, INFO, WARNING, ERROR)
LOG_DIR=logs           # Log dizini
LOG_INFO_FILE=info.log # Info log dosyası
LOG_ERROR_FILE=error.log # Error log dosyası

# Black-List Ayarları
BLACKLIST_FILE=black-list.lst  # Black-list dosya yolu
```

Black-List Yönetimi

Black-list dosyası `black-list.lst` her satıra bir domain olacak şekilde düzenlenir:

```
youtube.com
www.google.com
facebook.com
...
```

Yorum satırları `#` ile başlar:

```
# Sosyal medya siteleri
youtube.com
facebook.com
twitter.com
```

🗀 Proje Yapısı

```
sb-scrapper/
├── app/
│   ├── __init__.py
│   ├── main.py                # FastAPI ana uygulaması
│   ├── config.py              # Konfigürasyon yönetimi
│   ├── schemas.py             # Pydantic modelleri
│   ├── swagger_config.py      # Swagger UI özelleştirme
│   │
│   ├── core/
│   │   ├── __init__.py
│   │   ├── browser.py         # Tarayıcı yöneticisi
│   │   ├── blacklist.py       # Black-list yönetimi
│   │   └── logger.py          # Loguru loglama
│   │
│   ├── payloads/
│   │   ├── __init__.py
│   │   ├── noise_js.py        # Canvas noise JavaScript
```

```
│   │   └── sentinel_js.py      # Popup temizleme JavaScript
│   │
│   └── utils/
│       ├── __init__.py
│       └── user_agents.py      # User Agent listesi
│
├── static/
│   └── swagger-ui.css          # Swagger UI özel stilleri
│
├── logs/                       # Log dosyaları (runtime'da oluşturulur)
│
├── black-list.lst              # Black-list domain listesi
├── requirements.txt            # Python bağımlılıkları
├── Dockerfile                  # Docker imajı
├── docker-compose.yml          # Docker Compose konfigürasyonu
├── .env.example                # Örnek ortam değişkenleri
└── .gitignore                  # Git ignore dosyası
```

❓ Sık Karşılaşılan Sorular

Q: Tarayıcı neden headless modda çalışıyor?

A: Headless mod, sunucu ortamlarında grafik arayüz olmadan çalışmak için kullanılır. Headless modu kapatmak için `.env` dosyasında `HEADLESS=false` yapın.

Q: BUSY hatası alıyorum, ne yapmalıyım?

A: Tarayıcı şu anda başka bir işlemde. Birkaç saniye bekleyip tekrar deneyin veya `force_refresh: true` parametresini kullanarak tarayıcıyı yeniden başlatın.

Q: Captcha çözülmüyor, ne yapmalıyım?

A: Bazı captcha türleri otomatik çözülemeyebilir. Bu durumda:

1. `wait_time` değerini artırın
2. `force_refresh: true` ile tarayıcıyı yeniden başlatın
3. Manuel müdahale için headless modu kapatın

Q: Black-list'e yeni domain nasıl eklenir?

A: `black-list.lst` dosyasına her satıra bir domain ekleyin:

```
example.com
www.example.com
```

Q: Log dosyaları nerede?

A: Varsayılan olarak `logs/` klasöründe:

- `info.log` - INFO seviyesindeki loglar
- `error.log` - ERROR seviyesindeki loglar

Q: Docker konteyneri başlamıyor, ne yapmalıyım?

A: Konteyner loglarını kontrol edin:

```
docker-compose logs sb-scraper
```

Q: Memory leak görüyorum, ne yapmalıyım?

A: `force_refresh: true` parametresini kullanarak tarayıcıyı düzenli olarak yeniden başlatın.

Lisans

Bu proje MIT Lisansı altında lisanslanmıştır. Detaylar için LICENSE dosyasına bakın.

Teşekkürler

- SeleniumBase - Güçlü web scraping kütüphanesi
- FastAPI - Modern web framework
- Loguru - Güzel loglama kütüphanesi

SB-Scraper v2.0.0 - SeleniumBase tabanlı gelişmiş web scraping API'si